



ENGENHARIA INFORMÁTICA

Licenciatura em Engenharia Informática

Projeto em Engenharia Informática 2016/2017

Previsão de Níveis de Enchimento em Estações de Abastecimento Industriais

Projeto Continental FoF

José Barros (nº 73804), Sérgio Magalhães (nº 73623)

Equipa de Orientação:

Professor Vítor Filipe

José Ribeiro

Introdução

Um dos desafios no setor da indústria é a monitorização constante dos níveis de enchimento das estações de armazenamento (áreas onde são depositados matérias primas para utilização na produção que devem ser repostas regularmente), o que é crítico para garantir a eficiência do processo e evitar interrupções de produção. A monitorização manual destes níveis pode ser demorada, imprecisa e suscetível a erros humanos portanto uma previsão automática destes dados facilitaria muito esta tarefa de monitorização e reduziria os erros a ela associados. É aqui que a previsão baseada em algoritmos de “deep learning” se torna numa solução eficaz. Estes algoritmos são capazes de aprender com dados passados e prever com precisão o nível de enchimento futuro das estações, ajudando as empresas a tomar decisões informadas de quando devem proceder ao reabastecimento e garantir a continuidade da produção.

Materiais

A obtenção dos dados utilizados no modelo de “deep learning” foi realizada através de uma câmara presente no local. Esta câmara tirava fotos periódicas às colunas de abastecimento. A informação destas fotos era depois armazenada numa base de dados que seria, posteriormente utilizada no modelo. É de notar que alguns eventos, como por exemplo, a travessia de uma pessoa pelas colunas de abastecimento no momento em que a câmara estava a efetuar um registo resultaria na eliminação desse registo.

	F1	F2	F3	F6	F8	F9	F10	F13	F14	F15	F16	F17	F18
Time													
2022-12-05 09:05:31	94.0	64.0	64.0	0.0	0.0	50.0	0.0	0.0	0.0	77.0	100.0	100.0	100.0
2022-12-05 09:21:59	90.0	65.0	65.0	21.0	0.0	46.0	0.0	0.0	0.0	76.0	100.0	100.0	100.0
2022-12-05 09:27:23	90.0	65.0	65.0	21.0	0.0	46.0	0.0	0.0	0.0	76.0	100.0	100.0	100.0
2022-12-05 09:32:47	90.0	65.0	65.0	21.0	0.0	46.0	0.0	0.0	0.0	76.0	100.0	100.0	100.0
2022-12-05 09:38:11	89.0	64.0	64.0	21.0	0.0	44.0	0.0	0.0	1.0	76.0	100.0	100.0	98.0
...
2023-02-08 14:06:06	44.0	86.0	90.0	85.0	89.0	94.0	95.0	93.0	37.0	64.0	96.0	95.0	95.0
2023-02-08 14:11:06	44.0	85.0	90.0	85.0	89.0	94.0	95.0	93.0	37.0	64.0	96.0	95.0	95.0
2023-02-08 14:16:06	44.0	85.0	90.0	85.0	89.0	94.0	95.0	93.0	37.0	64.0	96.0	95.0	95.0
2023-02-08 14:21:06	44.0	86.0	90.0	85.0	89.0	94.0	95.0	93.0	37.0	64.0	96.0	95.0	95.0
2023-02-08 14:26:06	44.0	85.0	90.0	85.0	89.0	94.0	95.0	93.0	37.0	64.0	96.0	95.0	95.0

Figura 1 – Estrutura do “dataset”

Conclusões

Os resultados deste trabalho permitem concluir que apesar de um erro considerável relativo ao nosso modelo, este ainda é útil e capaz de ajudar no processo de automação da monitorização dos níveis de enchimento das estações de armazenamento. Um ponto a melhorar no futuro seria justamente a performance do mesmo, percebermos a diferença do comportamento do mesmo em relação às diferentes colunas e tentar corrigir a existência de “outliers” nos dados.

Método

As previsões dos modelos LSTM e GRU eram feitas tendo em conta os primeiros cinco valores existentes, ou seja, eram utilizados os primeiros cinco valores existentes para ser previsto o sexto valor, de seguida, o primeiro valor utilizado anteriormente é removido e o último valor dos cinco utilizados é a previsão feita no passo anterior.

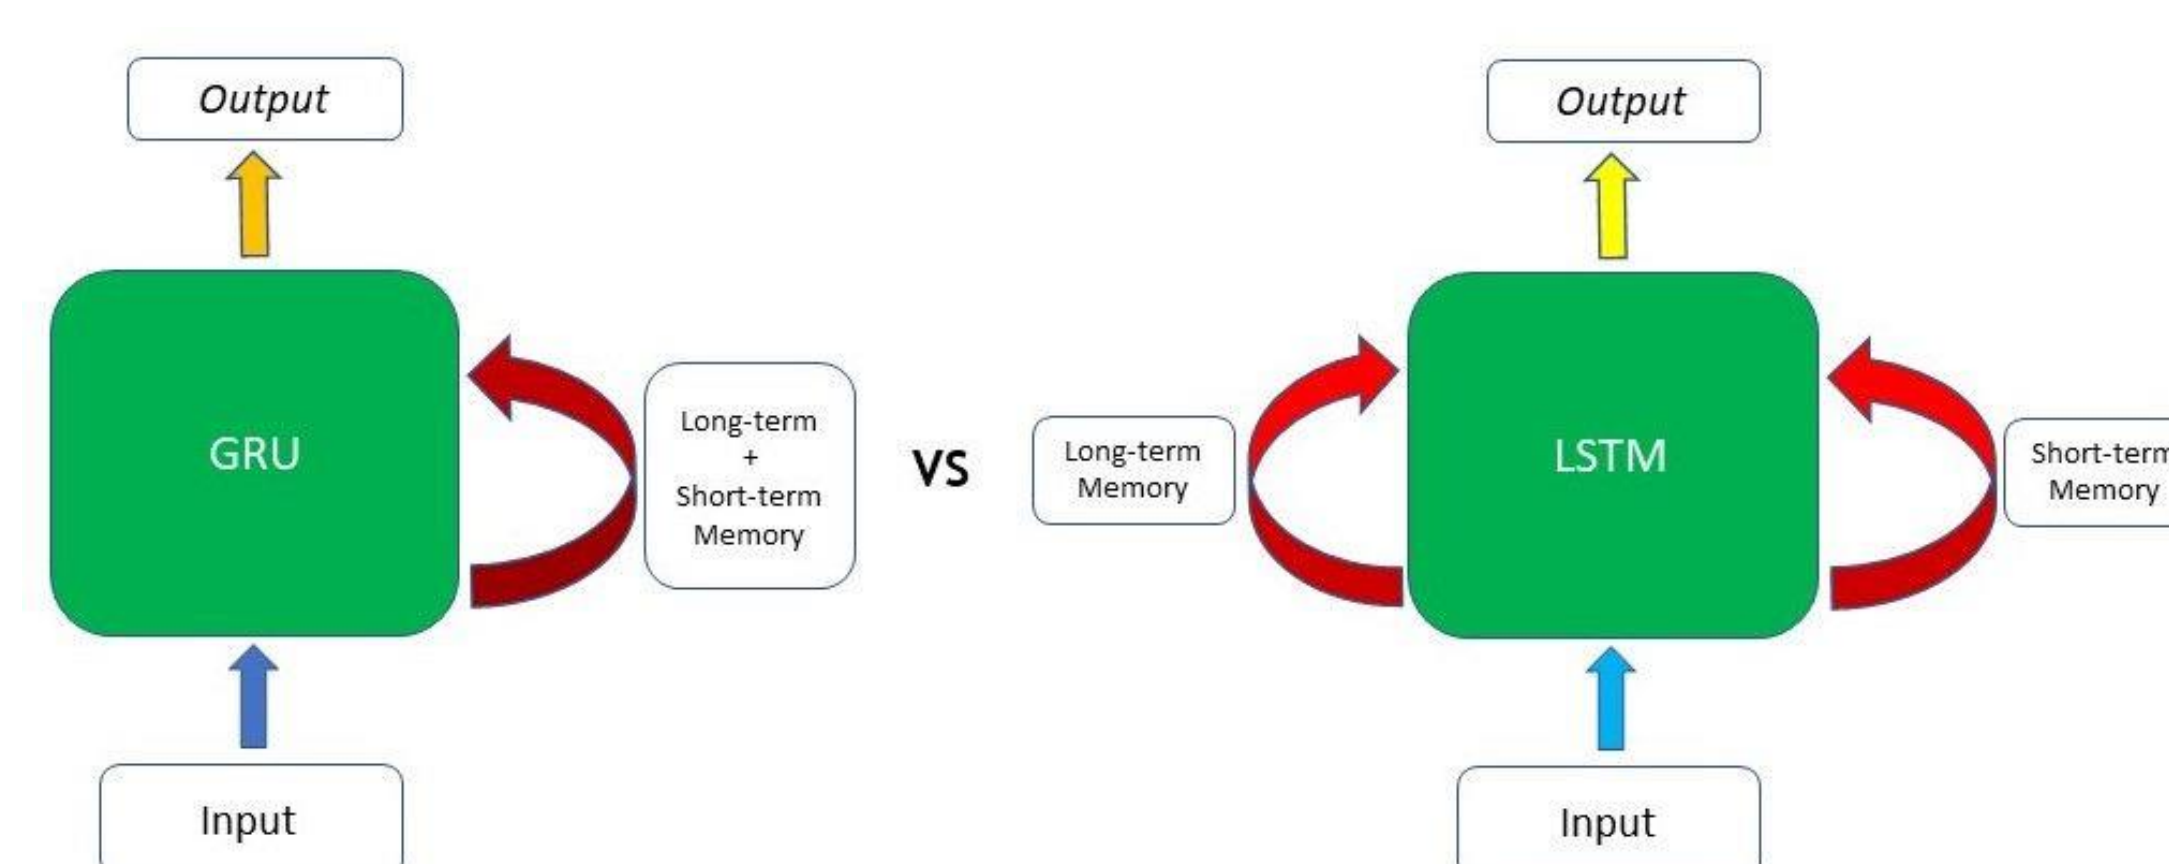


Figura 2 – Estrutura geral de um modelo GRU comparada com a de um modelo LSTM

Resultados

De forma a determinarmos qual o melhor modelo usamos algumas métricas muito comuns para determinar a performance de um modelo. As métricas utilizadas neste caso foram o “Mean Absolute Error” (MAE), o “Symmetric Mean Absolute Percentage Error” (sMAPE) e o “Root Mean Squared Error” (RMSE). É possível afirmar, então, pelas figuras 3 e 4 que o modelo LSTM apresentou uma melhor performance que o modelo GRU. Podemos assim, através destas métricas considerar o nosso modelo satisfatório no entanto os erros representados pelas métricas ainda são consideráveis e devem ser tidos em conta.

LSTM			
Métricas	SMAPE	MAE	RMSE
Média	17,2933	7,67279	11,603

Figura 3 – Média das métricas para o modelo LSTM

GRU			
Métricas	SMAPE	MAE	RMSE
Média	17,5533	7,86113	11,7834

Figura 4 – Média das métricas para o modelo GRU